



UNIVERSIDAD
AUSTRAL

| INGENIERÍA

ANÁLISIS DE SERIES TEMPORALES

Forecast en Características de Audio de Tracks en Spotify

Diana Bohórquez

Trabajo Práctico 1 | MEDGC 20/21 | Comisión B | 31 de Julio de 2021

Resumen Ejecutivo

Se propone en este trabajo práctico predecir el comportamiento de dos de las variables que describen características del audio de un set de canciones en Spotify. Se realizan una serie de test estadísticos y análisis gráficos para determinar el modelo ARIMA que mejor describe estas series, se procede a generar el modelo hacer pronósticos con él y medir su performance.

El valor en la selección de estas variables está en trabajar el modelado de series temporales en aplicaciones diferentes a las típicamente usadas como, por ejemplo, forecast de medidas económicas, financieras o el clima.

Tabla de contenido

Resumen Ejecutivo	1
Introducción.....	3
Propiedades de las series temporales	4
Descomposición y test de estacionariedad en Valence	6
Descomposición y test de estacionariedad en Energy	8
Funciones de Autocorrelación y Autocorrelación Parcial.....	9
Análisis de Autocorrelación en Energy	11
Análisis de Autocorrelación en Valence.....	11
Modelado	12
Serie temporal Energy.....	13
Selección del modelo y análisis de diagnóstico	13
Pronóstico con el modelo	15
Serie temporal Valence.....	17
Selección del modelo y análisis de diagnóstico	17
Pronóstico con el modelo	19
Análisis de Resultados.....	20
Serie temporal Energy.....	20
Serie temporal Valence.....	20
Conclusiones.....	21
Bibliografía.....	22

Introducción

Si se refiere a datos de YouTube, Netflix o Spotify intuitivamente cualquiera puede responder qué producción musical o audiovisual es un hit: si lleva tiempo siendo muy vista o escuchada o si rompió algún record de visitas estamos ante un producto pop. Para el caso de Spotify, en su página de desarrollador ellos mencionan, por ejemplo, que la *popularity* de una canción es de hecho un valor calculado por un algoritmo basado, en mayor medida, en la cantidad de reproducciones que tiene una canción. Pero, ¿cómo se puede explicar esta popularidad?

Spotify ha estructurado información no estructurada para explicar en términos de datos la música, definiendo variables como *loudness* (volumen general de una pista en dB), *liveness* (probabilidad que el track se realizó en vivo) o *acousticness* (medida de confianza de si la pista es acústica o no). Una breve exploración de estas y otras variables se encuentra en la notebook [TimeSeries ARIMA Spotify](#). Varios datasets de Spotify están disponible en [Kaggle](#), siendo particularmente útil para este trabajo práctico `data_o.csv`.

De acuerdo a esa exploración, a la oportunidad de buscar analizar series de comportamiento no estacionario y a la definición que Spotify da a sus variables, se preseleccionaron para este trabajo práctico *energy* y *valence*:

- **release_date** contiene la fecha de lanzamiento, la mayoría con formato yyyy-mm-dd. Para trabajar el dataset como serie temporal este se seteará como index y se agrupan sus datos por trimestre.
- **energy** con un rango de 0.0 a 1.0 representa una medida perceptiva de intensidad y actividad. Por lo general, las pistas enérgicas se sienten rápidas y ruidosas. Por ejemplo, el death metal tiene mucha energía, mientras que un preludio de Bach tiene una puntuación baja en la escala. Las características de percepción que contribuyen a este atributo incluyen rango dinámico, volumen percibido, timbre, frecuencia de inicio y entropía general.
- **valence**: con un rango de 0.0 a 1.0 valence describe la positividad musical que transmite una pista. Las pistas con valencia alta suenan más positivas (por ejemplo, feliz, alegre, eufórico), mientras que las pistas con valencia baja suenan más negativas (para el caso de adjetivos como triste, deprimido, enojado).

Es interés para este trabajo práctico pronosticar el comportamiento futuro de estas dos variables haciendo uso de análisis de series temporales.

El trabajo práctico está estructurado en cinco capítulos: los tres primeros se dedican a la descripción de las series, la identificación del modelo y su modelo con evaluación de su performance al pronosticar. En el apartado de análisis de resultados se enumera las principales observaciones hechas en el desarrollo del trabajo. Por último, se presentan unas breves conclusiones y sugerencias de futuros trabajos.

Propiedades de las series temporales

Graficar las series originales. Analizar si es necesario diferenciarlas para convertirlas en estacionarias. Exponer los conceptos relacionados con la estacionariedad de la serie. Utilizar como criterio un test de raíces unitarias que consideren pertinente.




Imagen 1. Evolución temporal de las variables de acuerdo a su media trimestral

Visualmente ninguna de las series parece estacionaria, ya que por lo pronto se evidencian en ellas cierta tendencia en *valence*, por ejemplo, una negativa y en *energy* una positiva. Para testear la hipótesis de estacionariedad se correrán test de raíces unitarias, pero antes de esto se repasarán someramente las propiedades que describen una serie temporal.

Una **serie temporal** es la representación de una variable y su evolución en el tiempo a intervalos regulares. Si esta evolución es estadísticamente estable en el tiempo, particularmente con respecto a la media y la varianza, se dice que la **serie es estacionaria**. Una simple definición de si un proceso es estacionario es si todos los posibles lags, k , con distribución de probabilidad $y_t, y_{t+1}, \dots, y_{t+k}$ no dependen del tiempo, t . Visualmente se puede tener una intuición acerca de la estacionariedad o no de una variable, por ejemplo, si el valor medio de la variable crece o decrece en intervalos de tiempo, si la amplitud entre los valores máximos y mínimos varían en el tiempo, o si parece existir un patrón que se repite a lo largo de la serie temporal se está ante una serie no estacionaria (Peña, 2010).

Un test de hipótesis para determinar si una serie es o no estacionaria es el test **Dickey-Fuller Aumentado (ADF)**, el cual tiene como hipótesis nula que hay una raíz unitaria en la serie¹ concentrándose particularmente en si la media de la serie cambia con el tiempo. El marco para el test de Dickey-Fuller plantea lo siguiente:

$$\Delta y_t = y_t - y_{t-1} = \alpha + \beta y_{t-1} + \epsilon_t \quad (1)$$

Siendo la hipótesis nula² $H_0: \beta = 1$ lo que significa que la serie tiene raíz unitaria, es decir que la serie no es estacionaria y la hipótesis alternativa $H_1: \beta < 1$ que implicaría que la serie temporal podría ser estacionaria.

Se mencionó que el test ADF mostraba particular interés en la evolución de la media, en contraste y en relación a la varianza, esta se maneja más con transformaciones que con un test formal (Nielsen, 2020), siendo usuales las siguientes:

- Transformación por diferencia: típicamente usado para remover tendencia de una serie.
- Las transformaciones por el logaritmo y la raíz cuadrada son particularmente útiles para el caso de cambios en la varianza en el tiempo.
- Tomando el cambio proporcional

Hasta ahora se ha hablado de las características de una serie estacionaria, del test comúnmente usado para rechazar o no la hipótesis de estacionariedad de una variable o de las transformaciones necesarias para hacerla estacionaria. Es el turno, entonces, de hablar de las características que hacen a una **serie no estacionaria** (Hyndman & Athanasopoulos, 2018):

- En una serie temporal la **tendencia** indica que sobre un largo periodo de tiempo la serie decrece o crece, sin que implique que estos cambios sean lineales.
- La **estacionalidad** ocurre por razones de estación, puede ser un aumento de suscripciones en el gimnasio a inicios de años o de mes, o mayor venta de

¹ Una serie temporal lineal es no estacionaria si existe una raíz unitaria, aunque la ausencia de una raíz unitaria no demuestra la estacionariedad

² Esta hipótesis también indica que el proceso es un random walk.

helados en los meses de verano. En este caso la frecuencia es fija o conocida en la serie de tiempo

- Similar a la estacionalidad una serie es **cíclica** si se observan patrones que se repiten a lo largo del tiempo, pero se diferencia en que la frecuencia no es fija.

Identificar si la serie tiene uno o varios de estos comportamientos es importante a la hora de elegir cómo modelarlas y los métodos que pueden capturar cada una de estas señales.

Por último, se destaca la importancia de contar con datos estacionarios o de hacer las transformaciones necesarias para lograrlo, toda vez que gran cantidad de modelos de series temporales trabajan sobre procesos estacionarios. Esto se explica desde el hecho que al buscar en un modelo estimar la media de una serie temporal con una media o varianza variables, el sesgo y el error también variarán con el tiempo lo que hará indefectiblemente que los resultados del modelo sean cuestionables.

Descomposición y test de estacionariedad en Valence

Al analizar una a una las componentes de la descomposición de la variable valence se observa:

- Una ligera tendencia positiva hasta el año 1980 y notablemente negativa de 1980 a 2008 aproximadamente. Esta tendencia puede ser capturada por el modelo incluyendo una componente autorregresiva AR.
- Parece haber un claro patrón estacional en la serie fluctuando entre los valores 0.0075 y -0.0075. Intuitivamente se puede pensar que esto está presente en los lanzamientos anuales (cada enero o primer trimestre) que son claramente superiores a los demás meses del año. Esta señal puede ser modelada trabajando con un modelo SARIMA.
- No se aprecia un patrón en los residuos.




Imagen 2. Descomposición de la variable valence

Para comprobar lo observado gráficamente se corre el test ADF obteniendo como p -value 0.3980 con lo cual no se puede rechazar H_0 de tal forma que no se puede asumir estacionariedad en la serie.

Este resultado implica que la serie debe ser diferenciada para hacerla estacionaria. Después de esta transformación (p -value 2.94×10^{-30}) y analizando los gráficos de función de autocorrelación y autocorrelación parcial se tendrá una idea del orden del modelo ARIMA o SARIMA que mejor describa la serie.

Descomposición y test de estacionariedad en Energy

Para el caso de la variable energy se analiza lo siguiente de las componentes de la serie:

- Hay una clara tendencia positiva al pasar los años.
- Igual que en *valence* parece claro la existencia de estacionalidad en las series.
- Los residuos también parecen aleatorios.




Imagen 3. Descomposición de la variable energy

Para el caso de *energy* el test ADF arroja un *p-value* de 0.01715 rechazando H_0 , por lo tanto, la serie no es un random walk, entonces se rechaza que la serie sea estacionaria.

Este resultado es llamativo a la vista del análisis de descomposición de la serie. Algunas de las razones que pueden estar detrás de este resultado es que el test tiene poco poder en distinguir entre raíces unitarias y raíces unitarias cercanas o los datos puedan ser pocos para el test (Nielsen, 2020).

Una alternativa a este test es el **KPSS Test** que para el caso de la serie *energy* el *p-value* es de 0.01. En este test la H_0 nula es inversa la H_0 del test ADF, esto significa que,

si se rechaza la hipótesis nula del test KPSS, esto podría proveer evidencia que la serie es estacionaria (Analytics Vidhya, 2021).

Estos dos resultados, tanto el de ADF y KPSS, rechazan la hipótesis nula sobre la alternativa, por lo tanto, la serie es estacionaria. Siempre es mejor aplicar las dos pruebas para asegurarse de que la serie es realmente estacionaria. Los posibles resultados de la aplicación de estas pruebas de estacionariedad son los siguientes (Statsmodels, 2019):

- Si ambas pruebas concluyen que la serie es o no es estacionaria entonces, la serie es o no es estacionaria, respectivamente.
- Si el KPSS indica estacionariedad y el ADF indica no estacionariedad, entonces la serie es estacionaria por tendencia. En este caso es necesario eliminar la tendencia para que la serie sea estrictamente estacionaria.
- Si el KPSS indica no estacionariedad y el ADF indica estacionariedad, entonces la serie es estacionaria por diferencia. Se debe utilizar la diferenciación para hacer que la serie sea estacionaria.

A partir de estos resultados y graficando las funciones de autocorrelación y autocorrelación parcial sin diferenciar la serie se podrá tener una idea del orden del modelo.

Funciones de Autocorrelación y Autocorrelación Parcial

Graficar la FAS, FAC y FACP de las mismas en un solo gráfico y analizarlas, ¿qué puede inferir de los gráficos? Justificar con teoría.

Los modelos autorregresivos generalizan la idea de representar una variable como una dependencia lineal en sus valores pasados. Si una serie temporal dependiera solo de su último valor observado se estaría hablando de un proceso autorregresivo de primer orden y generalizando esta dependencia a p retardos se obtienen procesos autorregresivos de orden p representado como AR(p). Matemáticamente una serie temporal y_t estacionaria sigue un proceso AR(p) sí:

$$\hat{y}_t = y_t - \mu = \phi_1 \hat{y}_{t-1} + \dots + \phi_p \hat{y}_{t-p} + \epsilon_t \quad (2)$$

Donde μ es la media del proceso estacionario y_t , ϵ_t es un proceso de ruido blanco con varianza σ^2 y ϕ es el parámetros de autorregresión (entendido como una fracción del lag que representa) siendo sus valores entre $-1 < \phi < 1$ condiciones para hablar de estacionariedad (Peña, 2010).

Para poder detectar el orden autorregresivo de un modelo AR se utiliza la función de autocorrelación parcial (FACP). Una intuición de cómo funciona la FACP puede verse interpretando las ecuaciones (3):

$$\begin{aligned} \hat{y}_t &= \phi_{0,1} + \phi_{1,1} \hat{y}_{t-1} + \epsilon_{1t} \\ \hat{y}_t &= \phi_{0,2} + \phi_{1,2} \hat{y}_{t-1} + \phi_{2,2} \hat{y}_{t-2} + \epsilon_{2t} \\ \hat{y}_t &= \phi_{0,3} + \phi_{1,3} \hat{y}_{t-1} + \phi_{2,3} \hat{y}_{t-2} + \phi_{3,3} \hat{y}_{t-3} + \epsilon_{3t} \end{aligned} \quad (3)$$

Aquí los coeficientes $\phi_{p,k}$ representan los valores de las funciones de autocorrelaciones parciales para diferentes lags. Por ejemplo, el valor $\phi_{3,3}$ es el valor del tercer lag de la FACP y representa que tan significantes es para el modelo la suma de un tercer lag cuando ya se tienen dos lags. Más formalmente “se define el coeficiente de autocorrelación parcial de orden k , ϕ_k^p como el coeficiente de correlación entre observaciones separadas k periodos, cuando eliminamos de la relación entre las dos variables la dependencia lineal debida a los valores intermedios”³.

Estos modelos AR tienen muchos coeficientes de correlación diferente de cero al margen de que estos decrezcan con los retardos, los cuales los hacen ideales para representar series de memoria larga. Cuando se necesita representar señales de memoria corta se usan los procesos MA(p) o de medias móviles, la cual es una combinación lineal de las innovaciones en el proceso:

$$\hat{y}_t = y_t - \mu = \epsilon_t - \theta_1\epsilon_{t-1} - \dots - \theta_p\epsilon_{t-p} \quad (4)$$

En este caso, el parámetro del modelo MA θ se interpreta como una fracción del ruido del lag que representa e independiente de su valor el modelo es estacionario. Típicamente un modelo MA se analiza en considerando la función **la función de autocorrelación**.

En términos generales, las representaciones gráficas de estas dos funciones de correlaciones permiten:

- Identificar cualquier autocorrelación (estadísticamente) significativa, lo que implica que la serie puede ser pronosticada considerando su pasado.
- Se pueden observar que lags específicos contribuyen al modelo.
- Se observan también comportamientos estacionales
- Ayudan a seleccionar las órdenes del modelo que mejor se ajustará a los datos.
 - Para el caso de los modelos MA se debe observar la FAC, mientras que,
 - La función de autocorrelación parcial ayudan a identificar el orden para el modelo AR

³ La demostración y cita textual a esta definición de FACP se encuentra en la página 134 del libro de Peña

Análisis de Autocorrelación en Energy

La gráfica de autocorrelación de *energy* muestra que sus observaciones sucesivas están correlacionadas positivamente, pero al no decrecer rápidamente hacia cero sugiere que el proceso tiene efectivamente una tendencia con lo cual no sería estacionario ni el gráfico informativo (González Casimiro, 2009).




Imagen 4. Función de Autocorrelación y Autocorrelación Parcial de la variable Energy

Al diferenciar la variable parece corregirse la no estacionariedad sugerida en el FAC inicial y que un modelo funcional sería el MA(1). Para el caso de la FACP se estaría ante un modelo AR(4). En el lag 20 de la función de autocorrelación puede haber indicios de estacionalidad de la serie.




Imagen 5. Función de Autocorrelación y Autocorrelación Parcial de la variable Energy diferenciada

Estas dos comparaciones se realizan con el objeto de contrastar los dos test estadísticos para chequear estacionariedad descritos en el anterior apartado.

Análisis de Autocorrelación en Valence

Para el caso de *valence diferenciada* la función de autocorrelación sugiere un modelo MA(1) y la de autocorrelación parcial uno AR(3). En este análisis no se identifican categóricamente componentes de estacionalidad.




Imagen 6. Función de Autocorrelación y Autocorrelación Parcial de la variable Valence diferenciada

Modelado

En este apartado se realizará una estimación de las series temporales con distintos órdenes para un modelo ARIMA, dado que no se encontró evidencia categórica acerca de evidencia de estacionalidad para plantear modelos SARIMA.

En el anterior apartado se describió los modelos AR y MA. Un modelo ARIMA trae la contribución tanto de los efectos directos (AR) como los indirectos (MA) de un proceso estacionario e incluye la componente de Integración que es la que transforma la serie no estacionaria a estacionaria mediante diferenciaciones. El orden de I se refiere a la cantidad de diferenciaciones necesarias para transformar una serie a estacionaria siendo un valor típico y recomendado no más de 3.

En general los modelos de forecasting y en particular la construcción de modelos ARIMA sigue el proceso iterativo Box-Jenkins (Lazzeri, 2021), en el cual sigue cuatro etapas:

1. **Identificación:** en este paso por medio de la información disponible como por ejemplo las funciones de autocorrelación se intenta sugerir un modelo ARIMA que valga la pena ser modelada.
2. **Estimación:** para el caso de este trabajo práctico se hace uso de la librería `statsmodels.tsa` para inferir los parámetros que condicionan el modelo seleccionado: $\theta_1, \dots, \theta_q, \phi_1, \dots, \phi_p$
3. **Diagnóstico del modelo:** se realizan contrastes de diagnóstico donde se busca responder si los residuos están incorrelacionados y normalmente distribuidos.

Estos tres pasos se realizan de forma iterativa hasta que encontrar un modelo con ajuste adecuado.

4. Por último, y una vez seleccionado el mejor modelo se hace pronóstico con este.

Precisamente este proceso iterativo se realiza en esta sección para la serie temporales de *energy* y *valence*.

Serie temporal Energy

Considerando el análisis hecho sobre las funciones de autocorrelación se iteró sobre modelos hasta de órdenes AR(4) y MA(10) para la variable *energy*; a pesar de que los test de no estacionariedad indicaron que esta serie es estacionaria, la función de autocorrelación indicaba no estacionariedad razón por la cual también se iterará por un orden I(1).

Selección del modelo y análisis de diagnóstico

Habiendo corrido 109 modelos, los modelos que mejor puntuaron con AIC y/o BIC fueron los modelos ARIMA(0,1,3), ARIMA(2,1,1) o ARIMA(4,1,4). Interesante de este experimento es el hecho que efectivamente la serie necesitaría diferenciarse para poder tener un mejor ajuste.

MODELO	AIC	BIC	LJUNG-BOX	JARQUE-BERA
ARIMA(0,1,3)	-583.934	-571.462	0.89	0.97
ARIMA(2,1,1)	-583.459	-570.987	0.66	0.70
ARIMA(4,1,4)	-584.428	-556.366	1.00	0.77

Algunas conclusiones de estos resultados son:

- Dado el valor de AIC del modelo ARIMA(0,1,3) se puede inferir que este es el mejor predictor.
- Dado el valor de BIC del modelo ARIMA(4,1,4) se puede inferir que este es el que mejor explica al modelo.
- Dado los valores de p-value de JB no se puede rechazar la hipótesis nula que los residuos están normalmente distribuidos.
- Para el caso de los p-value de Ljung-Box no se puede rechazar la hipótesis nula que los residuos estén correlacionados, por lo tanto, no quedan señales sin capturar en el modelo.

Primando por un modelo parsimonioso se elige el modelo ARIMA (0,1,3) para la serie de *energy*.

$$\hat{y}_t = -0.936\epsilon_{t-1} + 0.185\epsilon_{t-3} \quad (6)$$

```

=====
SARIMAX Results
=====
Dep. Variable:          energy    No. Observations:          168
Model:                 SARIMAX(0, 1, 3)    Log Likelihood            295.967
Date:                 Sat, 31 Jul 2021    AIC                      -583.934
Time:                 14:07:42           BIC                      -571.462
Sample:              03-31-1961         HQIC                     -578.872
                  - 12-31-2002
Covariance Type:      opg
=====
              coef    std err          z      P>|z|      [0.025      0.975]
-----
ma.L1         -0.9360     0.088    -10.605     0.000    -1.109    -0.763
ma.L2          0.0410     0.117     0.352     0.725    -0.188     0.270
ma.L3          0.1846     0.083     2.224     0.026     0.022     0.347
sigma2         0.0017     0.000     9.237     0.000     0.001     0.002
=====
Ljung-Box (L1) (Q):                0.02    Jarque-Bera (JB):                0.79
Prob(Q):                           0.89    Prob(JB):                     0.67
Heteroskedasticity (H):              0.73    Skew:                          0.17
Prob(H) (two-sided):                0.24    Kurtosis:                      3.02
=====

Warnings:
[1] Covariance matrix calculated using the outer product of gradients (complex-step).

```

Imagen 7. Resumen de resultados para el modelo ARIMA(0,1,3) de energy

Viendo visualmente los residuos se comprueba que efectivamente estos están normalmente distribuidos, no presentan patrón y no hay una correlación entre ellos.




Imagen 8. Análisis de los residuos de la variable energy

Por la representación gráfica de los residuos además de las pruebas estadísticas se concluye que estos son similares al ruido blanco, esto significa que el modelo ha producido buenos resultados y que efectivamente en los residuos no hay patrones

subyacentes. También se visualiza que en términos de ACF no hay rezagos significativos para los residuos de un buen modelo ARIMA.

Pronóstico con el modelo

Usando los resultados de entrenamiento se hace pronóstico sobre los datos de dataset de testeo, considerando que el modelo seleccionado ARIMA(0,1,3).




Imagen 9. Forecast de Energy con un modelo ARIMA(0,1,3)

La predicción para esta serie temporal no resulta buena gráficamente hablando. Aunque en el principio puede que se acerque la predicción un poco más al dato realmente observado y con el tiempo pierda precisión estableciendo la predicción como la media, es un comportamiento esperado en las series temporales toda vez que en la medida que se quiere predecir valores más lejanos al último observado el modelo se vuelve cada vez menos eficiente en las predicciones. Algunas métricas acerca de la precisión del modelo son:

- MSE: 0.028107
- MAE: 0.001180
- RMSE: 0.034350

En la gráfica de AFC se sugirió un componente estacional en el lag 20. Se corrió un experimento para ver su contribución a las predicciones y gráficamente parece acompañar mejor el resultado, pero los resultados de precisión claramente empeoraron (MSE: 0.058761; MAE: 0.005054; RMSE: 0.071094).




Imagen 10. Forecast de Energy con un modelo SARIMA(0,1,3)(0,0,20,4)

Una forma de compensar esta pérdida de precisión en las predicciones de series temporales es usar el método de rolling forecast origin en el cual el origen o inicio de la predicción se está actualizando de periodo en periodo. Al correr el experimento visiblemente se ve que la predicción es más cercana a los datos de entrenamiento y también que mejoran las métricas de performance.

- MSE: 0.020059
- MAE: 0.000637
- RMSE: 0.025233




Imagen 11. Forecast de Energy con método Rolling Forecast Origin con modelo ARIMA(0,1,3)

Extendiendo la ventana de tiempo un par de años se puede predecir la evolución de energy hasta 2025. La selección de tan corto periodo se debe a que estamos hablando de un modelo de corta memoria.




Imagen 12. Forecast de Energy con método Rolling Forecast Origin hasta 2025 con modelo ARIMA(0,1,3)

Serie temporal Valence

Según las FAC y FACP el modelo sugerido para valence es un AR(3) y MA(1); el test de Augmented Dickey-Fuller había rechazado la H_0 con lo cual este modelo tiene un orden de integración $I(1)$

Selección del modelo y análisis de diagnóstico

Según los Criterios de Información los mejores modelos podrían ser ARIMA(1,1,1), ARIMA(0,1,1) o ARIMA(2,1,1).

MODELO	AIC	BIC	LJUNG-BOX	JARQUE-BERA
ARIMA(1,1,1)	-667.833	-658.479	0.77	0.04
ARIMA(0,1,1)	-664.182	-657.946	0.09	0.00
ARIMA(2,1,1)	-665.989	-653.517	0.76	0.03

Algunas conclusiones de estos resultados son:

- Dado el valor de AIC del modelo ARIMA(1,1,1) se puede inferir que este es el mejor predictor.
- Dado el valor de BIC del modelo ARIMA(1,1,1) se puede inferir que este es el que mejor explica al modelo.
- Dado los valores de p-value de Jarque-Bera se puede rechazar la hipótesis nula que los residuos están normalmente distribuidos.
- Para el caso de los p-value de Ljung-Box no se puede rechazar la hipótesis nula que los residuos estén correlacionados, por lo tanto, no quedan señales sin capturar en el modelo.

Primando por un modelo parsimonioso se elige el modelo ARIMA (1,1,1) para la serie de valence.

$$\hat{y}_t = -0.215t_{-1} - 0.883\epsilon_{t-1} \quad (7)$$

```

=====
SARIMAX Results
=====
Dep. Variable:    valence    No. Observations:    168
Model:            SARIMAX(1, 1, 1)    Log Likelihood        336.917
Date:             Sat, 31 Jul 2021    AIC                   -667.833
Time:             14:13:39           BIC                   -658.479
Sample:           03-31-1961         HQIC                  -664.037
               - 12-31-2002
Covariance Type:  opg
=====
              coef    std err          z      P>|z|      [0.025    0.975]
-----
ar.L1         -0.2153     0.087     -2.463     0.014     -0.387     -0.044
ma.L1         -0.8330     0.061    -13.668     0.000     -0.952     -0.714
sigma2         0.0010    9.98e-05    10.274     0.000     0.001     0.001
=====
Ljung-Box (L1) (Q):           0.09    Jarque-Bera (JB):           6.56
Prob(Q):                     0.77    Prob(JB):              0.04
Heteroskedasticity (H):       0.60    Skew:                  0.25
Prob(H) (two-sided):          0.06    Kurtosis:              3.83
=====

Warnings:
[1] Covariance matrix calculated using the outer product of gradients (complex-step).

```

Imagen 13. Resumen de resultados para el modelo ARIMA(1,1,1) de valence

A pesar que el test de Jarque-Bera sugiere que los residuos no están normalmente distribuidos, el gráfico de este si los muestra normalizados. En este caso, una posible solución es ver de cerca los outliers que presenta la serie.




Imagen 14. Análisis de los residuos de la variable valence

Pronóstico con el modelo

Usando los resultados de entrenamiento se hace pronóstico sobre los datos de dataset de testeo, considerando que el modelo seleccionado $ARIMA(1,1,1)$ usando el enfoque Rolling Forecast Origin. Para este caso las medidas de performance son: MSE 0.024020; MAE 0.000814; RMSE 0.028525.




Imagen 15. Forecast de Valence con método Rolling Forecast Origin con modelo $ARIMA(1,1,1)$

Análisis de Resultados

En este trabajo práctico se analizaron dos series que describen componentes auditivas de algunas de las canciones disponibles en Spotify. Se inició con una revisión sobre la descomposición de la serie (tendencia, estacionalidad y ruido) y se aplicaron test estadísticos para rechazar o no la hipótesis de estacionariedad. Sumando a esto y al análisis de funciones de autocorrelación se trabajaron sobre modelos ARIMA dado que no hubo fuerte evidencia de estacionalidad.

Los residuos generados por los modelos también tenían un comportamiento esperado, toda vez que por su comportamiento aleatorio y normalizado se evidenciaba que se había extraídos todas las componentes que describen las series.

En las dos series se presentó tendencia con lo cual hubo un orden de Integración en los modelos.

Como modelo para pronosticar las series resultaron mejores los que usaron el método de rolling forecast origin.

Serie temporal Energy

Con el pasar de los años las canciones lanzadas parecen cada vez más enérgicas. Si como muy enérgico se establece géneros como death metal, parece lógica esta tendencia cuando antes la música tenía componentes más melódicos.

Para el caso de esta serie se estaría ante un modelo IMA(1,3) dado que los resultados mostraron que el modelo con mejor ajuste es un ARIMA(0,1,3). Para este caso, energy usa lags de los errores en sus pronósticos pasados como un modelo de regresión lineal.

Fue interesante contrastar los dos test de estacionariedad, siendo su resultado rechazo de hipótesis nula y conocer que estos resultados indican que la serie es tendencia estacionaria.

Serie temporal Valence

La media de la serie valence está alrededor de 0.5 lo cual intuitivamente parece lógico: hay tantas canciones que evocan tristeza como las que evocan felicidad, aunque con el tiempo van hay una tendencia a producirse canciones más tristes.

Esta serie tiene una memoria muy corta dado que su componente AR es de solo un orden por lo cual sugiere que su capacidad de pronóstico es de un periodo a la vez.

A diferencia de la serie energy, y precisamente por ser un modelo ARIMA el pronóstico considera tanto su valor inmediatamente anterior como el error de pronóstico en ese lag.

Conclusiones

Los modelos ARIMA son comúnmente usados para el análisis de las series temporales no estacionarias. Estos modelos plantean el principio de que se pueden hacer pronósticos considerando la correlación lineal de un momento dado con sus valores pasados.

En este trabajo práctico se ha recorrido todo el proceso iterativo Box-Jenkins para sugerir el mejor modelo que se puede adaptar a las series, hacer un par de experimentos y quedarse con el que mejor performe y finalmente hacer pronósticos con este modelo. Para esto se utilizó el lenguaje de programación de Python.

El pronóstico de series temporales llega dado que tiene el potencial de predecir solo tantos intervalos futuros como lags haya estadísticamente significativos. Fue entonces interesante utilizar el modelo de Rolling forecasting Origin para compensar esta característica. Esta técnica permite obtener varios errores de pronóstico para series de tiempo, lo que permite comprender mejor cómo se comportan los modelos. Esto puede considerarse como una serie temporal análoga a las técnicas de cross validation.

Sería interesante ver variables exógenas que puedan ayudar a modelar estas series, por ejemplo, ver si eventos estacionarios como depresiones económicas o estallidos sociales hacen que se publiquen más o menos canciones “tristes” según la calificación de *valence* que da Spotify a las canciones.

Otro interesante trabajo podría ser utilizar estas dos series como variables exógenas para predecir la popularidad de una canción.

Bibliografía

- Analytics Vidhya. (16 de junio de 2021). *Statistical tests to check stationarity in Time Series*.
Obtenido de Analytics Vidhya:
<https://www.analyticsvidhya.com/blog/2021/06/statistical-tests-to-check-stationarity-in-time-series-part-1/>
- González Casimiro, M. (2009). *Análisis de Serie Temporales: Modelos ARIMA*. Lejona: Universidad del País Vasco.
- Hyndman, R. J., & Athanasopoulos, G. (2018). *Forecasting: Principles and Practice*. OTexts.
- Lazzeri, F. (2021). *Machine Learning for Time Series Forecasting with Python*. Indianapolis: Wiley.
- Nielsen, A. (2020). *Practical Time Series Analysis. Prediction with Statistics and Machine Learning*. Sebastopol: O'Reilly.
- Peña, D. (2010). *Análisis de Series Temporales*. Madrid: Alianza.
- Statsmodels. (2019). *Stationarity and detrending (ADF/KPSS)*. Obtenido de Statsmodels:
https://www.statsmodels.org/dev/examples/notebooks/generated/stationarity_detrending_adf_kpss.html