



ANÁLISIS DE SERIES TEMPORALES

Modelado y pronóstico del ozono troposférico,
la temperatura y la radiación solar en Los Ángeles

Trabajo Práctico N.º 2 — Trabajo Final

Maestría en Ciencia de Datos - Modalidad virtual

UNIVERSIDAD AUSTRAL

Docentes

Rodrigo Del Rosso - Sebastián Calcagno - Braian Drago

Integrantes:

Sol Gabriele Peruilh - Leonardo Gabriel Gastaldo -

Ezequiel Baglieri- Maximiliano Vergara Dominguez

Septiembre de 2026

Resumen Ejecutivo

El presente trabajo constituye la segunda etapa del estudio de tres series temporales horarias de la cuenca de Los Ángeles (California): la concentración de ozono troposférico (ppm), la temperatura del aire ($^{\circ}\text{C}$) y la radiación solar global horizontal (W/m^2), con registros entre enero de 1998 y agosto de 2025. En el Trabajo Práctico N.º 1 (TP1) estas series se modelaron mediante SARIMA, VAR y ensambles de árboles; el objetivo de esta etapa consiste en aplicar técnicas de Machine Learning, Deep Learning, modelos híbridos, AutoML y modelos fundacionales, y comparar su desempeño con el obtenido previamente.

Como paso previo se incorporó un tratamiento explícito de la calidad de los datos. Los valores atípicos se detectaron mediante la mediana y la desviación absoluta mediana (MAD) calculadas para la misma hora del día en una ventana móvil de ± 30 días. Sólo se corrigieron por interpolación los atípicos aislados (hasta tres horas consecutivas); los episodios sostenidos se conservaron por su compatibilidad con eventos atmosféricos reales. Además, se reconstruyeron 3.324 horas ausentes del índice temporal, lo que dio lugar a una base regular de 242.402 registros horarios.

Se evaluaron dieciséis configuraciones de modelos: dos modelos de espacio de estados, una red LSTM, Prophet y NeuralProphet, cuatro modelos de la librería Darts, AutoTS, tres regresores en MLForecast, los modelos fundacionales Chronos-Bolt y TimeGPT-2.1, y una implementación de TSMixer. Todos se evaluaron sobre las mismas 168 horas finales (20 al 27 de agosto de 2025) mediante MAE y RMSE.

En el experimento realizado, el menor MAE correspondió a Chronos-Bolt en ozono (0,0067 ppm, un 17 % menor que el mejor modelo del TP1) y a Random Forest en MLForecast en radiación solar (25,13 W/m^2 , un 9 % menor). En temperatura, ningún modelo de esta etapa

superó al VAR(48) del TP1 (1,06 °C); el mejor modelo nuevo fue ETSTModel (1,09 °C). Los resultados indican que la conveniencia de cada familia de modelos depende de la estructura de cada serie: los modelos preentrenados y los ensambles de árboles con variables de calendario reprodujeron mejor los ciclos diarios marcados, mientras que la temperatura se benefició de la dinámica conjunta que captura el VAR. El código completo se encuentra disponible en un repositorio público de GitHub (Gastaldo et al., 2026).

Índice de Contenido

Resumen Ejecutivo	2
Índice de Contenido	4
1. Introducción	5
1.1. Problemática y contexto.....	5
1.2. Motivación de esta etapa.....	5
1.3. Objetivos	6
2. Datos y preparación	6
2.1. Fuentes de datos	6
2.2. Limpieza y datos faltantes	7
2.3. Detección y tratamiento de atípicos	7
2.4. Caracterización de la base tratada.....	10
2.5. Protocolo de evaluación.....	11
3. Marco Teórico.....	12
3.1. Modelos de espacio de estados	12
3.2. Ensamblados de árboles y AutoML.....	12
3.3. Redes neuronales: LSTM y TSMixer	13
3.4. Modelos aditivos y con componentes neuronales: Prophet y NeuralProphet.....	14
3.5. Modelos de la librería Darts.....	14
3.6. Modelos fundacionales	14
4. Análisis de Resultados	15
4.1. Configuración de los modelos	15
4.2. Resultados por familia de modelos	16
4.3. Modelo seleccionado y pronóstico.....	18
4.4. Comparación con el TP1.....	19
5. Conclusiones	20
6. Referencias bibliográficas.....	21
7. Apéndices.....	25
Apéndice A. Código y reproducibilidad	25
Apéndice B. Configuración y resultados detallados	26
Apéndice C. Figuras complementarias	28

1. Introducción

1.1. Problemática y contexto

El ozono troposférico es un contaminante secundario: no se emite de forma directa, sino que se forma mediante reacciones fotoquímicas entre óxidos de nitrógeno y compuestos orgánicos volátiles en presencia de radiación solar. Por este motivo, su concentración presenta un ciclo diario asociado a la radiación y una modulación estacional vinculada con la temperatura, que acelera las reacciones involucradas. La cuenca de Los Ángeles constituye un caso de estudio adecuado para este fenómeno, dado que combina emisiones urbanas elevadas, alta insolación y condiciones meteorológicas que dificultan la dispersión de contaminantes.

Las tres series se eligieron por este vínculo físico: la radiación impulsa la formación de ozono y la temperatura modula su velocidad. A este criterio se sumaron dos requisitos prácticos: el acceso público a las fuentes y una longitud superior a 100.000 registros horarios por serie. Las tres series provienen de organismos oficiales de los Estados Unidos y cubren casi 28 años con frecuencia horaria.

1.2. Motivación de esta etapa

En el TP1 se estimaron modelos SARIMA, un modelo VAR(48) y ensambles de árboles (Peruilh et al., 2026). Aquellos resultados mostraron que ningún enfoque obtenía el menor error en las tres series: el VAR resultó preferible en temperatura, mientras que los ensambles de árboles se destacaron en ozono y radiación. Esta etapa amplía el conjunto de técnicas con modelos capaces de representar relaciones no lineales, estacionalidades múltiples y patrones aprendidos de grandes colecciones de series, con el propósito de determinar si alguno de ellos mejora los resultados previos.

1.3. Objetivos

Objetivo general. Modelar y pronosticar las series horarias de ozono troposférico, temperatura y radiación solar mediante técnicas de Machine Learning, Deep Learning, modelos híbridos, AutoML y modelos fundacionales, y comparar su desempeño con el de los modelos del TP1.

Objetivos específicos:

- Detectar y tratar valores atípicos y datos faltantes antes del modelado, con criterios documentados y reproducibles.
- Incorporar modelos de espacio de estados y de suavizado exponencial como referencia estadística adicional.
- Ajustar redes neuronales (LSTM y TSMixer), un modelo aditivo (Prophet) y uno híbrido (NeuralProphet), modelos de la librería Darts, herramientas de AutoML (AutoTS y MLForecast) y modelos fundacionales (Chronos-Bolt y TimeGPT).
- Comparar todos los modelos sobre una misma ventana de prueba de 168 horas y seleccionar un modelo por serie.
- Contrastar los resultados con los obtenidos en el TP1.

2. Datos y preparación

2.1. Fuentes de datos

La Tabla 1 resume el origen de cada serie. El período común abarca desde el 1 de enero de 1998 a las 08:00 UTC (00:00 hora local) hasta el 27 de agosto de 2025 a las 09:00 UTC. El inicio queda determinado por la disponibilidad del NSRDB y el final, por el último registro de NOAA disponible al momento de la descarga.

Tabla 1*Series analizadas y fuentes de datos*

Serie	Fuente	Ubicación	Frecuencia original
Ozono troposférico (ppm)	EPA AQS / AirData (U.S. Environmental Protection Agency, 2026)	Estación Los Angeles–North Main Street (06-037-1103)	Horaria
Temperatura (°C)	NOAA NCEI, Integrated Surface Database (Smith et al., 2011)	Aeropuerto de Los Ángeles, LAX (722950-23174)	Horaria
Radiación solar global horizontal (W/m ²)	NSRDB GOES Aggregated v4.0.0 (Sengupta et al., 2018)	Coordenadas de LAX (33,94; -118,41)	30 minutos

Nota. Todas las marcas temporales se expresan en UTC. El NSRDB es administrado por el National Laboratory of the Rockies (anteriormente National Renewable Energy Laboratory).

2.2. Limpieza y datos faltantes

La preparación de los datos se realizó en dos etapas. En la primera, correspondiente al TP1, se unificaron las tres fuentes en una grilla horaria, se interpolaron linealmente los huecos de hasta tres horas y se descartaron los intervalos faltantes más extensos, que representaban el 2,6 % de las filas. El resultado fue una base de 239.078 registros con marcas temporales ausentes. En la segunda etapa, incorporada en este trabajo, esas 3.324 horas faltantes (1,37 % de la grilla completa) se reconstruyeron mediante interpolación lineal sobre un índice horario regular. Se obtuvo así una base de 242.402 registros sin valores faltantes, requisito de librerías como Darts y MLForecast.

2.3. Detección y tratamiento de atípicos

Los criterios basados en la media y el desvío estándar resultan poco adecuados para estas series, porque los propios atípicos inflan la dispersión y porque el ciclo diario llevaría a clasificar como anómalos valores normales del mediodía. Por este motivo se adoptó un criterio robusto basado en la mediana y la desviación absoluta mediana (Leys et al., 2013), calculadas para cada hora del día sobre una ventana móvil de 60 observaciones de esa misma hora (± 30 días). Una observación se considera atípica cuando cumple:

$$|y_t - Me_h(t)| > k \cdot b \cdot MAD_h(t), \quad \text{con } k = 6 \text{ y } b = 1,4826 \quad (1)$$


donde $Me_h(t)$ y $MAD_h(t)$ son la mediana y la MAD locales de la hora h . La constante b vuelve comparable la MAD con el desvío estándar bajo normalidad, y el valor $k = 6$ fija un umbral deliberadamente conservador. Los atípicos se clasificaron según su persistencia: las rachas de hasta tres horas consecutivas se trataron como errores de medición y se reemplazaron por interpolación lineal; las rachas más extensas se conservaron sin cambios, por resultar más compatibles con episodios reales de contaminación o de calor que con fallas del instrumento. La Tabla 2 resume los resultados y la Figura 1 muestra la ubicación de los atípicos en toda la serie.

Tabla 2
Atípicos detectados y tratamiento aplicado por serie

Serie	Atípicos detectados	% del total	Aislados (corregidos)	Sostenidos (conservados)
Ozono	11.912	4,98 %	4.027	7.885
Temperatura	849	0,36 %	480	369
Radiación solar	5.259	2,20 %	3.318	1.941


Nota. Porcentajes calculados sobre 239.078 registros. Elaboración propia a partir del notebook 07b_tratamiento_datos.

Figura 1
Atípicos detectados en las tres series (1998–2025)



Nota. En naranja, atípicos aislados (corregidos); en rojo, atípicos sostenidos (conservados). Elaboración propia a partir del notebook 07b_tratamiento_datos.

La Figura 2 compara la serie original y la tratada durante un mes representativo. Las diferencias se limitan a los atípicos aislados, mientras que el resto de la trayectoria se mantiene sin cambios.

Figura 2*Serie original y serie tratada durante junio de 2020*

Nota. La línea gris discontinua corresponde a la serie original y la línea de color, a la serie tratada. Elaboración propia a partir del notebook 07b_tratamiento_datos.

2.4. Caracterización de la base tratada

Tabla 3*Estadísticas descriptivas de la base tratada (N = 242.402)*

Serie	Media	Desv. est.	Median a	P25	P75	Mín.	Máx.	Asimetría
Ozono (ppm)	0,0214	0,0185	0,0190	0,0040	0,0340	0,0000	0,1480	0,79
Temperatura (°C)	17,08	3,99	17,10	14,40	19,43	1,70	39,40	0,24
Radiación (W/m²)	227,96	310,03	19,00	0,00	437,50	0,00	1.065,00	1,11

Nota. Elaboración propia a partir de serie_california_tratada.csv.

La radiación presenta un 47,7 % de registros con valor cero, correspondientes principalmente a las horas nocturnas, lo que genera una distribución asimétrica y constituye una de las principales dificultades para los modelos que no incorporan información horaria. El análisis de estacionariedad del TP1 (pruebas ADF, KPSS y Phillips-Perron) concluyó que las tres series son estacionarias en nivel y fijó una diferencia estacional de período 24 para representar el ciclo diario en los modelos lineales (Peruillh et al., 2026).

2.5. Protocolo de evaluación

Para todos los modelos se reservaron las últimas 168 horas (del 20 de agosto de 2025 a las 10:00 UTC al 27 de agosto de 2025 a las 09:00 UTC) como conjunto de prueba. El horizonte de una semana abarca siete ciclos diarios completos, lo que permite evaluar la capacidad de cada modelo para reproducir el ciclo día-noche y su evolución entre días. Los modelos de esta etapa se entrenaron con el año previo a la ventana de prueba y ninguno utilizó observaciones de esas 168 horas durante el ajuste. En el caso de los modelos fundacionales, la evaluación se realizó mediante inferencia zero-shot, sin ajuste fino sobre las series analizadas; no es posible verificar si datos públicos similares formaron parte de su preentrenamiento.

El desempeño se midió mediante el error absoluto medio (MAE) y la raíz del error cuadrático medio (RMSE):

$$MAE = (1/H) \sum_t |y_t - \hat{y}_t|, \quad RMSE = \sqrt{[(1/H) \sum_t (y_t - \hat{y}_t)^2]}, \quad H = 168 \quad (2)$$

El MAE se utiliza como criterio principal de selección, por expresarse en las unidades de cada serie y ser menos sensible a errores extremos; el RMSE se informa como complemento. No se emplea el MAPE, porque resulta indefinido cuando la serie toma el valor cero, situación frecuente en la radiación nocturna y, en menor medida, en el ozono.

La comparación con el TP1 presenta una salvedad: los modelos SARIMA, VAR y skforecast se estimaron sobre la base sin el tratamiento descrito en las secciones 2.2 y 2.3. Dentro de la ventana de prueba, ambas bases difieren en dos horas de temperatura (hasta 2,0 °C) y en tres horas de radiación (hasta 269 W/m²); en ozono son idénticas. Las comparaciones entre etapas deben leerse con esta consideración.

3. Marco Teórico

Los modelos de esta etapa se agrupan en seis familias. Los modelos del TP1 —SARIMA, VAR y ensambles de árboles (Random Forest, XGBoost y LightGBM) estimados con skforecast (Amat Rodrigo y Escobar Ortiz, 2026; Chen y Guestrin, 2016)— se describieron en el informe anterior (Peruilh et al., 2026) y se utilizan aquí como referencia.

3.1. Modelos de espacio de estados

Un modelo de espacio de estados representa la serie observada en función de un vector de estado no observable que evoluciona en el tiempo (Durbin y Koopman, 2012):

$$y_t = Z \alpha_t + \varepsilon_t, \quad \alpha_{t+1} = T \alpha_t + R \eta_t \quad (3)$$

El filtro de Kalman estima el estado de forma recursiva y permite calcular la verosimilitud para estimar las varianzas de los componentes. Se evaluaron dos especificaciones de statsmodels (Seabold y Perktold, 2010): un modelo de componentes no observables con nivel local y estacionalidad de 24 períodos (Harvey, 1989), y el modelo ETS de suavizado exponencial con error y estacionalidad aditivos, que constituye la formulación en espacio de estados del método de Holt-Winters (Hyndman et al., 2008). La autocorrelación de los errores se evaluó mediante la prueba de Ljung-Box (Ljung y Box, 1978).

3.2. Ensamblados de árboles y AutoML

Los modelos de Machine Learning tabular convierten el pronóstico en un problema de regresión, en el que cada valor se explica a partir de sus rezagos y de variables de calendario:

$$y_t = f(y_{t-1}, \dots, y_{t-p}, x_t) + \varepsilon_t \quad (4)$$

El horizonte completo se obtiene de forma recursiva: cada predicción se incorpora como rezago del paso siguiente. Random Forest promedia árboles entrenados sobre muestras bootstrap (Breiman, 2001), mientras que LightGBM construye árboles de manera secuencial mediante

gradient boosting (Ke et al., 2017). En esta etapa se utilizó MLForecast (Nixtla, 2026a), que automatiza la construcción de rezagos y de variables de calendario, con tres regresores:

LightGBM, Random Forest y regresión lineal. AutoTS (Catlin, 2026) automatiza la selección del modelo mediante un algoritmo genético que combina transformaciones de los datos y familias de modelos, descarta las configuraciones que no pueden ejecutarse o validarse y elige la de menor error en validación temporal.

3.3. Redes neuronales: LSTM y TSMixer

Las redes LSTM (Hochreiter y Schmidhuber, 1997) incorporan una celda de memoria regulada por compuertas que determinan qué información se conserva, se incorpora o se transmite, lo que atenúa el problema del desvanecimiento del gradiente en secuencias largas:

$$c_t = f_t \odot c_{t-1} + i_t \odot \tilde{c}_t, \quad h_t = o_t \odot \tanh(c_t) \quad (5)$$

donde f_t , i_t y o_t son las compuertas de olvido, entrada y salida. TSMixer (Chen et al., 2023) prescinde de la recurrencia y de los mecanismos de atención: alterna perceptrones multicapa que mezclan información a lo largo del tiempo (*time-mixing*) y entre variables (*channel-mixing*), con conexiones residuales y normalización por capas:

$$X' = X + MLP_t(LN(X)), \quad Y = X' + MLP_v(LN(X')) \quad (6)$$

donde MLP_t opera sobre el eje temporal, MLP_v sobre las variables y LN denota la normalización por capas. A diferencia de la LSTM empleada, que pronostica un paso por vez y reutiliza sus propias predicciones, TSMixer genera las 168 horas en una única salida. La LSTM se implementó en TensorFlow/Keras (Abadi et al., 2016) y TSMixer, en PyTorch (Paszke et al., 2019).

3.4. Modelos aditivos y con componentes neuronales: Prophet y NeuralProphet

Prophet (Taylor y Letham, 2018) descompone la serie en tendencia, estacionalidades y efectos de eventos especiales, y representa cada estacionalidad de período P mediante una serie de Fourier:

$$y(t) = g(t) + s(t) + h(t) + \varepsilon_t, \quad s(t) = \sum_n [a_n \cos(2\pi nt/P) + b_n \sin(2\pi nt/P)] \quad (7)$$

NeuralProphet (Triebe et al., 2021) conserva esta descomposición e incorpora un componente autorregresivo implementado como red neuronal (AR-Net), que le permite aprovechar los valores recientes de la serie. Por combinar una descomposición estadística con una red neuronal, constituye el modelo híbrido de esta familia; Prophet, en cambio, es un modelo aditivo.

3.5. Modelos de la librería Darts

Darts (Unit8, 2026) ofrece una interfaz común para distintos modelos de pronóstico. Se evaluaron cuatro: suavizado exponencial de Holt-Winters; AutoARIMA, que selecciona el orden del modelo mediante criterios de información (Nixtla, 2026b); el método Theta (Assimakopoulou y Nikolopoulos, 2000); y un modelo basado en la transformada rápida de Fourier (FFT), que extrapola los componentes de frecuencia dominantes de la serie.

3.6. Modelos fundacionales

Los modelos fundacionales para series temporales se preentrenan sobre grandes colecciones de series de distintos dominios y pueden pronosticar series nuevas sin reentrenamiento (inferencia zero-shot). Chronos (Ansari et al., 2024) adapta la arquitectura del modelo de lenguaje T5 al pronóstico. Se utilizó la variante Chronos-Bolt (Amazon Science, 2024), que divide la historia en parches de observaciones consecutivas y pronostica de forma directa los cuantiles de todo el horizonte; como pronóstico puntual se tomó la mediana.

TimeGPT (Garza et al., 2023) es un modelo basado en *transformers* de uso comercial, disponible a través de una API; se utilizó la versión timegpt-2.1 (Nixtla, 2026c).

4. Análisis de Resultados

4.1. Configuración de los modelos

Las decisiones de configuración buscaron una comparación equitativa; el detalle completo de hiperparámetros figura en el Apéndice B. La mayoría de los modelos incorpora el ciclo diario en su propia estructura (estacionalidad de 24 períodos en los modelos de espacio de estados y en Darts, series de Fourier en Prophet y NeuralProphet) o mediante variables de calendario (hora y día de la semana en MLForecast). Por coherencia, TimeGPT recibió las mismas variables de calendario y TSMixer se entrenó con la hora del día, codificada como seno y coseno, en dos canales adicionales; esta modificación redujo su MAE en radiación de 69,26 a 52,30 W/m² respecto de la versión inicial de un único canal. Los modelos fundacionales se evaluaron sin ajuste fino y sin variables exógenas: el uso de los valores futuros de temperatura y radiación como predictores del ozono le habría otorgado a TimeGPT información de la que ningún otro modelo dispuso.

Dos ajustes adicionales surgieron de la revisión de los pronósticos. En NeuralProphet, el pronóstico recursivo de 168 pasos producía valores negativos en ozono y radiación, por lo que cada predicción se acotó en cero antes de reincorporarse como rezago. En Chronos-Bolt se utilizó un horizonte de 168 pasos para mantener la homogeneidad con el resto de los modelos, aunque la librería recomienda horizontes de hasta 64 pasos; esta configuración debe considerarse al interpretar sus resultados.

4.2. Resultados por familia de modelos

La Tabla 4 reúne los resultados de todas las familias, incluidos los modelos del TP1; el Apéndice B presenta el detalle de cada configuración individual y el Apéndice C, los pronósticos de cada modelo.

Tabla 4

MAE y RMSE de todos los modelos sobre la ventana de prueba de 168 horas

Modelo	Etap	Ozono MAE	Ozono RMSE	Temp. MAE	Temp. RMSE	Rad. MAE	Rad. RMSE
SARIMA(1,0,1)(1,1,1) ₂₄	TP1	0,0111	0,0138	2,04	2,51	34,87	67,40
VAR(48)	TP1	0,0083	0,0110	1,06	1,31	34,18	83,51
skforecast ^a	TP1	0,0082	0,0106	1,51	1,91	27,57	66,01
UnobservedComponents	TP2	0,0160	0,0197	1,18	1,53	84,14	114,78
ETSModel	TP2	0,0162	0,0200	1,09	1,36	71,75	91,45
LSTM	TP2	0,0117	0,0160	3,47	4,23	62,89	90,98
TSMixer	TP2	0,0091	0,0112	1,73	2,09	52,30	72,36
Prophet	TP2	0,0090	0,0119	2,17	2,56	85,51	92,36
NeuralProphet	TP2	0,0086	0,0122	1,38	1,77	58,38	69,82
Darts ^b	TP2	0,0094	0,0114	1,19	1,53	45,18	65,22
AutoTS ^c	TP2	0,0107	0,0146	1,16	1,52	50,18	88,71
MLForecast ^d	TP2	0,0110	0,0149	1,99	2,48	25,13	53,29
Chronos-Bolt	TP2	0,0067	0,0096	1,50	1,91	25,98	47,89
TimeGPT-2.1	TP2	0,0069	0,0095	1,71	2,06	25,68	47,67

Nota. Ozono en ppm, temperatura en °C y radiación en W/m². En negrita, el menor valor de cada columna. Mejor configuración por serie: ^a XGBoost en ozono y LightGBM en temperatura y radiación; ^b FFT en ozono y suavizado exponencial en temperatura y radiación; ^c GLS, SectionalMotif y SeasonalityMotif, respectivamente; ^d regresión lineal en ozono, LightGBM en temperatura y Random Forest en radiación. Los modelos del TP1 se estimaron sobre la base sin tratar (sección 2.5).

Espacio de estados. ETSModel obtuvo un MAE de 1,09 °C en temperatura, el segundo menor del estudio, con una especificación univariada de pocos parámetros. En ozono y radiación, en cambio, ambos modelos presentaron errores superiores a los del SARIMA del TP1. La prueba de Ljung-Box rechazó la hipótesis de ausencia de autocorrelación en los errores de pronóstico de las seis combinaciones ($p < 0,001$), resultado coincidente con el diagnóstico de SARIMA en el TP1 que indica estructura no capturada por las especificaciones lineales.

Redes neuronales. La LSTM reprodujo la forma del ciclo diario del ozono (MAE = 0,0117 ppm), pero sus errores aumentaron en temperatura (3,47 °C) y radiación (62,89 W/m²). El

pronóstico recursivo acumula el error de cada paso a lo largo de las 168 horas, lo que se tradujo en una atenuación progresiva de los máximos diarios (Figura C4). TSMixer, que genera el horizonte completo en una única salida, obtuvo menores errores en temperatura ($1,73\text{ }^{\circ}\text{C}$) y radiación ($52,30\text{ W/m}^2$).

Prophet y NeuralProphet. NeuralProphet redujo el MAE de Prophet en las tres series, con la mayor diferencia en temperatura (de $2,17$ a $1,38\text{ }^{\circ}\text{C}$, un 36% menos). En radiación ambos modelos registraron errores elevados ($85,51$ y $58,38\text{ W/m}^2$): la representación mediante senos y cosenos produce una curva suave que se adapta mal al paso abrupto entre la noche, con valores iguales a cero, y el día.

Darts. El modelo FFT obtuvo el menor error de la librería en ozono ($0,0094\text{ ppm}$) y el suavizado exponencial, en temperatura y radiación ($1,19\text{ }^{\circ}\text{C}$ y $45,18\text{ W/m}^2$). AutoARIMA presentó el mayor error en radiación ($285,16\text{ W/m}^2$). El método Theta no pudo aplicarse al ozono ni a la radiación, porque su descomposición estacional multiplicativa requiere valores estrictamente positivos, condición que ambas series no cumplen.

AutoML. AutoTS seleccionó un modelo distinto para cada serie y obtuvo el tercer menor MAE en temperatura ($1,16\text{ }^{\circ}\text{C}$). En MLForecast, Random Forest alcanzó el menor MAE del estudio en radiación ($25,13\text{ W/m}^2$): los árboles de decisión, combinados con la hora del día como variable, reproducen de forma directa los valores nocturnos iguales a cero.

Modelos fundacionales. Chronos-Bolt y TimeGPT obtuvieron los menores errores en ozono (MAE de $0,0067$ y $0,0069\text{ ppm}$) y valores cercanos al mínimo en radiación ($25,98$ y $25,68\text{ W/m}^2$), sin ajuste ni entrenamiento específico sobre las series analizadas. TimeGPT registró además el menor RMSE en radiación ($47,67\text{ W/m}^2$), lo que indica menos errores de gran

magnitud que Random Forest pese a un MAE levemente mayor. En temperatura, ambos modelos (1,50 y 1,71 °C) quedaron por detrás del VAR y de los modelos de espacio de estados.


4.3. Modelo seleccionado y pronóstico

Con el MAE como criterio principal, la Tabla 5 presenta el modelo seleccionado para cada serie y la Figura 3 muestra su pronóstico sobre la ventana de prueba.

Tabla 5
Modelo seleccionado para cada serie

Serie	Modelo seleccionado	Etap a	MAE	RMSE	Alternativa más cercana (MAE)
Ozono	Chronos-Bolt (zero-shot)	TP2	0,0067 ppm	0,0096 ppm	TimeGPT-2.1 (0,0069 ppm)
Temperatura	VAR(48)	TP1	1,06 °C	1,31 °C	ETSTModel (1,09 °C)
Radiación solar	MLForecast – Random Forest	TP2	25,13 W/m ²	53,29 W/m ²	TimeGPT-2.1 (25,68 W/m ²)

Figura 3
Pronóstico del modelo seleccionado para cada serie (20 al 27 de agosto de 2025)



Nota. Arriba a la izquierda, ozono (Chronos-Bolt); arriba a la derecha, radiación solar (MLForecast – Random Forest); abajo, temperatura (VAR(48)). En los paneles superiores, el eje horizontal indica las horas desde el inicio de la ventana de prueba. Elaboración propia a partir de los notebooks 12_foundation_models, 11_automl y 06_var.

La ventana de siete días resulta adecuada para este experimento en función de la periodicidad de las series: contiene siete ciclos diarios completos —el patrón dominante en las

tres variables—, permite evaluar la capacidad de los modelos para reproducir el ciclo día-noche y su evolución entre días, y coincide con el horizonte del TP1, lo que hace posible la comparación entre etapas. Los tres modelos reproducen la fase del ciclo diario. Chronos-Bolt subestima los máximos de ozono en los días de mayor concentración; Random Forest reproduce los valores nocturnos iguales a cero y la amplitud de la mayoría de los días, con sobreestimaciones en las jornadas de menor radiación; y el VAR sigue la evolución de la temperatura, con desvíos en los máximos de los días más cálidos.

4.4. Comparación con el TP1

Tabla 6

Mejor modelo de cada etapa y variación del MAE

Serie	Mejor modelo TP1	MAE TP1	Mejor modelo TP2	MAE TP2	Variación
Ozono	skforecast – XGBoost	0,00816 ppm	Chronos-Bolt	0,00675 ppm	–17,3 %
Temperatura	VAR(48)	1,062 °C	ETSMModel	1,090 °C	+2,6 %
Radiación solar	skforecast – LightGBM	27,57 W/m ²	MLForecast – Random Forest	25,13 W/m ²	–8,9 %

Nota. Variación = (MAE TP2 – MAE TP1) / MAE TP1; los valores negativos indican un menor error en el TP2. En ozono y temperatura se muestra un decimal adicional respecto de la Tabla 4, para que la variación pueda reproducirse a partir de los valores publicados.

Los modelos de esta etapa redujeron el error en dos de las tres series. La mejora en ozono proviene de un modelo sin ajuste ni entrenamiento específico sobre las series del estudio. Este resultado podría ser consistente con una transferencia adecuada de los patrones temporales aprendidos durante el preentrenamiento; sin embargo, el experimento no permite identificar qué características de esos datos lo explican. En radiación, el mejor modelo pertenece a la misma familia que en el TP1 (ensambles de árboles con variables de calendario); la diferencia podría asociarse con la configuración de rezagos de MLForecast y, en parte, con las tres horas de la ventana de prueba en que difieren las bases (sección 2.5). En temperatura, la dinámica conjunta

con la radiación y el ozono que captura el VAR, estimado sobre toda la historia, no fue superada por los modelos univariados de esta etapa.

5. Conclusiones

Ningún modelo obtuvo el menor error en las tres series, por lo que la selección debe realizarse para cada una. En ozono, Chronos-Bolt redujo un 17,3 % el error del mejor modelo del TP1, sin ajuste específico sobre la serie; en radiación, Random Forest en MLForecast lo redujo un 8,9 %; en temperatura, el VAR(48) del TP1 conservó el menor error.

El factor común entre los modelos con menor error fue la capacidad de representar el ciclo diario: mediante variables de calendario (Random Forest), mediante la dinámica conjunta de 48 rezagos de las tres variables (VAR) o mediante los patrones aprendidos en el preentrenamiento (Chronos-Bolt). Los modelos que representan el ciclo día-noche de forma suave o sin información horaria explícita —Prophet, los modelos de espacio de estados y la LSTM— registraron en radiación errores entre 2,5 y 3,4 veces mayores que el del modelo seleccionado.

Estos resultados se circunscriben a una única ventana de prueba de 168 horas y a una sola ubicación. Otras limitaciones son la diferencia de bases entre etapas, el uso de Chronos-Bolt con un horizonte superior al recomendado, la ejecución de TimeGPT-2.1 mediante una API externa, cuyo procesamiento interno no es observable, y la ausencia de precursores químicos del ozono y de viento entre las variables.

Como mejoras futuras se proponen tres líneas. La primera consiste en trasladar el tratamiento de atípicos y datos faltantes del notebook 07b a la etapa de análisis exploratorio, de modo que todos los modelos, incluidos los del TP1, se estimen sobre la misma base. La segunda, en optimizar los hiperparámetros de los modelos que lo permiten: con excepción de AutoTS,

cuya búsqueda es automática, los modelos de esta etapa se evaluaron con configuraciones fijas o por defecto, por lo que sus errores constituyen una referencia conservadora; esta optimización puede incluir el ajuste fino de los modelos fundacionales, aplicado con un criterio común a ambos. La tercera, en validar los resultados con múltiples ventanas móviles (*rolling origin*) a lo largo del año.

En síntesis, para las series analizadas, los modelos preentrenados y los ensambles de árboles con información horaria superaron a los modelos estadísticos clásicos en ozono y radiación, mientras que en temperatura el VAR conservó el menor error. El aporte central del trabajo es un flujo reproducible que compara 21 configuraciones de modelos bajo un mismo protocolo y permite seleccionar, con evidencia cuantitativa, el modelo adecuado para cada serie.

6. Referencias bibliográficas

- Abadi, M., Barham, P., Chen, J., Chen, Z., Davis, A., Dean, J., Devin, M., Ghemawat, S., Irving, G., Isard, M., Kudlur, M., Levenberg, J., Monga, R., Moore, S., Murray, D. G., Steiner, B., Tucker, P., Vasudevan, V., Warden, P., ... Zheng, X. (2016). TensorFlow: A system for large-scale machine learning. En *12th USENIX Symposium on Operating Systems Design and Implementation (OSDI 16)* (pp. 265–283). USENIX Association.
- Amat Rodrigo, J. y Escobar Ortiz, J. (2026). *skforecast* (Versión 0.23.0) [Software]. <https://skforecast.org>
- Amazon Science. (2024). *chronos-forecasting* [Software]. GitHub. <https://github.com/amazon-science/chronos-forecasting>
- Ansari, A. F., Stella, L., Turkmen, C., Zhang, X., Mercado, P., Shen, H., Shchur, O., Rangapuram, S. S., Pineda Arango, S., Kapoor, S., Zschiegner, J., Maddix, D. C., Wang, H., Mahoney, M. W., Torkkola, K., Wilson, A. G., Bohlke-Schneider, M. y Wang, Y.

- (2024). *Chronos: Learning the language of time series* [Preprint]. arXiv.
<https://doi.org/10.48550/arXiv.2403.07815>
- Assimakopoulos, V. y Nikolopoulos, K. (2000). The theta model: A decomposition approach to forecasting. *International Journal of Forecasting*, 16(4), 521–530.
[https://doi.org/10.1016/S0169-2070\(00\)00066-2](https://doi.org/10.1016/S0169-2070(00)00066-2)
- Breiman, L. (2001). Random forests. *Machine Learning*, 45(1), 5–32.
<https://doi.org/10.1023/A:1010933404324>
- Catlin, C. (2026). *AutoTS* (Versión 1.0.4) [Software]. GitHub.
<https://github.com/winedarksea/AutoTS>
- Chen, S.-A., Li, C.-L., Yoder, N., Arik, S. Ö. y Pfister, T. (2023). TSMixer: An all-MLP architecture for time series forecasting. *Transactions on Machine Learning Research*.
<https://doi.org/10.48550/arXiv.2303.06053>
- Chen, T. y Guestrin, C. (2016). XGBoost: A scalable tree boosting system. En *Proceedings of the 22nd ACM SIGKDD International Conference on Knowledge Discovery and Data Mining* (pp. 785–794). <https://doi.org/10.1145/2939672.2939785>
- Durbin, J. y Koopman, S. J. (2012). *Time series analysis by state space methods* (2.^a ed.). Oxford University Press.
- Garza, A., Challu, C. y Mergenthaler-Canseco, M. (2023). *TimeGPT-1* [Preprint]. arXiv.
<https://doi.org/10.48550/arXiv.2310.03589>
- Gastaldo, L. G., Peruilh, S. G., Baglieri, E. y Vergara Dominguez, M. (2026). *Series_AMBA: Análisis y pronóstico de series temporales de ozono, temperatura y radiación solar* [Código fuente]. GitHub. https://github.com/LeonardoGastaldo/Series_AMBA

- Harvey, A. C. (1989). *Forecasting, structural time series models and the Kalman filter*. Cambridge University Press.
- Hochreiter, S. y Schmidhuber, J. (1997). Long short-term memory. *Neural Computation*, 9(8), 1735–1780. <https://doi.org/10.1162/neco.1997.9.8.1735>
- Hyndman, R. J., Koehler, A. B., Ord, J. K. y Snyder, R. D. (2008). *Forecasting with exponential smoothing: The state space approach*. Springer.
- Ke, G., Meng, Q., Finley, T., Wang, T., Chen, W., Ma, W., Ye, Q. y Liu, T.-Y. (2017). LightGBM: A highly efficient gradient boosting decision tree. *Advances in Neural Information Processing Systems*, 30, 3146–3154.
- Leys, C., Ley, C., Klein, O., Bernard, P. y Licata, L. (2013). Detecting outliers: Do not use standard deviation around the mean, use absolute deviation around the median. *Journal of Experimental Social Psychology*, 49(4), 764–766. <https://doi.org/10.1016/j.jesp.2013.03.013>
- Ljung, G. M. y Box, G. E. P. (1978). On a measure of lack of fit in time series models. *Biometrika*, 65(2), 297–303. <https://doi.org/10.1093/biomet/65.2.297>
- Nixtla. (2026a). *MLForecast* (Versión 1.1.0) [Software]. GitHub. <https://github.com/Nixtla/mlforecast>
- Nixtla. (2026b). *StatsForecast* (Versión 2.1.1) [Software]. GitHub. <https://github.com/Nixtla/statsforecast>
- Nixtla. (2026c). *TimeGPT: Documentación* [Documentación técnica]. <https://www.nixtla.io/docs>
- Paszke, A., Gross, S., Massa, F., Lerer, A., Bradbury, J., Chanan, G., Killeen, T., Lin, Z., Gimelshein, N., Antiga, L., Desmaison, A., Köpf, A., Yang, E., DeVito, Z., Raison, M., Tejani, A., Chilamkurthy, S., Steiner, B., Fang, L., ... Chintala, S. (2019). PyTorch: An

- imperative style, high-performance deep learning library. *Advances in Neural Information Processing Systems*, 32, 8024–8035.
- Peruilh, S. G., Gastaldo, L. G., Baglieri, E. y Vergara Dominguez, M. (2026). *Análisis de series temporales: Modelado y pronóstico del ozono troposférico, la temperatura y la radiación solar en Los Ángeles* [Trabajo práctico N.º 1, Maestría en Ciencia de Datos]. Universidad Austral.
- Seabold, S. y Perktold, J. (2010). Statsmodels: Econometric and statistical modeling with Python. En *Proceedings of the 9th Python in Science Conference* (pp. 92–96).
<https://doi.org/10.25080/Majora-92bf1922-011>
- Sengupta, M., Xie, Y., Lopez, A., Habte, A., Maclaurin, G. y Shelby, J. (2018). The National Solar Radiation Data Base (NSRDB). *Renewable and Sustainable Energy Reviews*, 89, 51–60. <https://doi.org/10.1016/j.rser.2018.03.003>
- Smith, A., Lott, N. y Vose, R. (2011). The Integrated Surface Database: Recent developments and partnerships. *Bulletin of the American Meteorological Society*, 92(6), 704–708.
<https://doi.org/10.1175/2011BAMS3015.1>
- Taylor, S. J. y Letham, B. (2018). Forecasting at scale. *The American Statistician*, 72(1), 37–45.
<https://doi.org/10.1080/00031305.2017.1380080>
- Triebe, O., Hewamalage, H., Pilyugina, P., Laptev, N., Bergmeir, C. y Rajagopal, R. (2021). *NeuralProphet: Explainable forecasting at scale* [Preprint]. arXiv.
<https://doi.org/10.48550/arXiv.2111.15397>
- Unit8. (2026). *Darts* (Versión 0.46.1) [Software]. GitHub. <https://github.com/unit8co/darts>
- U.S. Environmental Protection Agency. (2026). *AirData: Pre-generated data files* [Conjunto de datos]. https://aqs.epa.gov/aqsweb/airdata/download_files.html

7. Apéndices

Apéndice A. Código y reproducibilidad

El código completo se encuentra en el repositorio del proyecto en GitHub (Gastaldo et al., 2026). La Tabla A1 describe los notebooks y módulos utilizados.

Tabla A1

Notebooks y módulos del proyecto

Archivo	Contenido
01_descarga_datos	Descarga automática de EPA AQS, NOAA ISD y NSRDB (requiere API key de NSRDB)
02_limpieza	Unificación de fuentes, grilla horaria e interpolación de huecos de hasta 3 h
03_eda	Análisis exploratorio, descomposición estacional y ACF/PACF
04_estacionariedad	Pruebas ADF, KPSS y Phillips-Perron; órdenes de diferenciación
05_sarima / 06_var / 07_pronosticos	Modelos del TP1: SARIMA, VAR(48) y ensambles con skforecast
07b_tratamiento_datos	Atípicos, huecos del índice, UnobservedComponents, ETSModel y Ljung-Box
08_lstm	Red LSTM (TensorFlow/Keras)
09_prophet_neuralprophet	Prophet y NeuralProphet
10_darts	Suavizado exponencial, AutoARIMA, Theta y FFT
11_automl	AutoTS y MLForecast
12_foundation_models	Chronos-Bolt, TimeGPT-2.1 (requiere API key de Nixtla) y TSMixer
src/descarga.py, src/limpieza.py	Funciones de descarga y de lectura y combinación de las fuentes
src/utills.py, src/dl_utills.py	Estructura de carpetas y registro; ventanas supervisadas y escalado

Los experimentos se ejecutaron en Windows 11, sin GPU, con Python 3.12.13. Las versiones principales fueron: pandas 2.3.3, NumPy 2.4.6, scikit-learn 1.8.0, statsmodels 0.14.6, skforecast 0.23.0, TensorFlow 2.21.0, PyTorch 2.11.0, PyTorch Lightning 1.9.5, Prophet 1.4.0, NeuralProphet 0.8.0, Darts 0.46.1, StatsForecast 2.1.1, AutoTS 1.0.4, MLForecast 1.1.0, LightGBM 4.6.0, XGBoost 3.4.1, chronos-forecasting 2.3.1 y nixtla 0.8.0. Las semillas fijadas fueron 123 (TensorFlow, skforecast y MLForecast) y 42 (TSMixer). En redes que inspeccionan el tráfico HTTPS, la descarga de modelos y la API de Nixtla requieren el paquete truststore.

Apéndice B. Configuración y resultados detallados

Tabla B1

Configuración de cada modelo

Modelo	Base y entrenamiento	Configuración principal
SARIMA	Sin tratar; último año	Búsqueda por AIC con $p, q, P, Q \in \{0, 1\}$; $d = 0, D = 1, s = 24$
VAR	Sin tratar; historia completa	Series con diferencia estacional; orden por AIC (máx. 48) $\rightarrow p = 48$
skforecast	Sin tratar; historia completa	Rezagos 1, 2, 3, 24, 48 y 72; hora, día de la semana y mes; búsqueda bayesiana de 15 intentos con validación sobre los últimos 60 días
UnobservedComponents	Tratada; último año	Nivel local; estacionalidad de 24 períodos
ETSMModel	Tratada; último año	Error aditivo, sin tendencia, estacionalidad aditiva de 24
LSTM	Tratada; último año	Entrada de 24 h; LSTM(64) y capa densa lineal; Adam, MSE; 50 épocas; lote de 256; escalado $[-1, 1]$; pronóstico recursivo
TSMixer	Tratada; último año	Canales: serie, seno y coseno de la hora; 168 h de entrada y de salida; 2 bloques, dimensión oculta 64; Adam (tasa 10^{-3}), MSE; 100 épocas
Prophet	Tratada; último año	Estacionalidad diaria y semanal; sin estacionalidad anual ni feriados
NeuralProphet	Tratada; último año	24 rezagos; un paso por vez (recursivo); 30 épocas; tasa 0,01; predicciones acotadas en cero en ozono y radiación
Darts	Tratada; último año	Suavizado exponencial, AutoARIMA, Theta y FFT con valores por defecto
AutoTS	Tratada; último año	Perfil superfast; 5 generaciones; 2 validaciones; sin ensamble
MLForecast	Tratada; último año	Rezagos 1, 2, 3, 24 y 48; hora y día de la semana; LightGBM, Random Forest (200 árboles) y regresión lineal
Chronos-Bolt	Tratada; contexto del último año	chronos-bolt-small; zero-shot; 168 pasos; mediana
TimeGPT	Tratada; último año	timegpt-2.1; hora y día de la semana; zero-shot; sin exógenas

Tabla B2

Resultados de cada configuración sobre la ventana de prueba

Modelo	Etap	Ozono MAE	Ozono RMSE	Temp. MAE	Temp. RMSE	Rad. MAE	Rad. RMSE
SARIMA	TP1	0,0111	0,0138	2,04	2,51	34,87	67,40
VAR(48)	TP1	0,0083	0,0110	1,06	1,31	34,18	83,51
skforecast – LightGBM	TP1	0,0084	0,0104	1,51	1,91	27,57	66,01
skforecast – XGBoost	TP1	0,0082	0,0106	1,69	2,11	32,23	64,90
skforecast – Random Forest	TP1	0,0100	0,0127	2,01	2,41	39,05	71,19
UnobservedComponents	TP2	0,0160	0,0197	1,18	1,53	84,14	114,78


Modelo	Etapas	Ozono MAE	Ozono RMSE	Temp. MAE	Temp. RMSE	Rad. MAE	Rad. RMSE
ETSModel	TP2	0,0162	0,0200	1,09	1,36	71,75	91,45
LSTM	TP2	0,0117	0,0160	3,47	4,23	62,89	90,98
TSMixer	TP2	0,0091	0,0112	1,73	2,09	52,30	72,36
Prophet	TP2	0,0090	0,0119	2,17	2,56	85,51	92,36
NeuralProphet	TP2	0,0086	0,0122	1,38	1,77	58,38	69,82
Darts – Suavizado exp.	TP2	0,0173	0,0209	1,19	1,53	45,18	65,22
Darts – AutoARIMA	TP2	0,0164	0,0206	1,75	2,25	285,16	315,44
Darts – Theta	TP2	—	—	1,28	1,57	—	—
Darts – FFT	TP2	0,0094	0,0114	3,01	3,32	68,16	94,44
AutoTS	TP2	0,0107	0,0146	1,16	1,52	50,18	88,71
MLForecast – LightGBM	TP2	0,0117	0,0143	1,99	2,48	29,93	53,51
MLForecast – Random Forest	TP2	0,0111	0,0133	2,14	2,45	25,13	53,29
MLForecast – Regresión lineal	TP2	0,0110	0,0149	3,40	3,97	246,64	306,37
Chronos-Bolt	TP2	0,0067	0,0096	1,50	1,91	25,98	47,89
TimeGPT-2.1	TP2	0,0069	0,0095	1,71	2,06	25,68	47,67

Nota. Ozono en ppm, temperatura en °C y radiación en W/m². Theta no pudo aplicarse a ozono ni a radiación (sección 4.2).

Apéndice C. Figuras complementarias

Figura C1


Horas ausentes del índice temporal por año, antes de la reconstrucción



Nota. Elaboración propia a partir del notebook 07b_tratamiento_datos.

Figura C2


Series tratadas, con la ubicación de los atípicos corregidos y conservados



Nota. Elaboración propia a partir del notebook 07b_tratamiento_datos.


Figura C3

Pronósticos de UnobservedComponents y ETSModel




Nota. Elaboración propia a partir del notebook 07b_tratamiento_datos.

Figura C4
Curvas de entrenamiento y pronósticos de la red LSTM



Nota. Elaboración propia a partir del notebook 08_lstm.


Figura C5
Pronósticos de Prophet y NeuralProphet



Nota. Elaboración propia a partir del notebook 09_prophet_neuralprophet.


Figura C6

Pronósticos del mejor modelo de Darts por serie




Nota. Elaboración propia a partir del notebook 10_darts.

Figura C7
Pronósticos de AutoTS y MLForecast



Nota. Elaboración propia a partir del notebook 11_automl.

Figura C8
Pronósticos de Chronos-Bolt, TSMixer y TimeGPT-2.1



Nota. Elaboración propia a partir del notebook 12_foundation_models.